

FacePredictor

Prédiction d'âge, de genre et d'ethnicité par
Deep Learning

SAE BUT3 Informatique 2025-2026

Ako Christian Carl D Similien Noe Cervera Dhanoush Kessavane

Encadrement : Bilal Faye

Sommaire

1. Démonstration de l'application
2. Comment ça marche ? (Détection de visage)
3. Les 3 stratégies de modélisation
4. Mixture of Experts (initiative personnelle)
5. Comparaison des architectures
6. Avantages et inconvénients de chaque mode
7. Résultats
8. Difficultés et perspectives

Démonstration

Démo en direct de l'application

1. Photo

Prendre une photo
ou importer
depuis la galerie

2. Détection

MediaPipe détecte
et isole le visage
automatiquement

3. Résultat

Age, genre et
ethnicité prédits
avec confiance

Fonctionne aussi en temps réel via la camera

Détection de visage MediaPipe

Pourquoi c'est nécessaire ?

Nos modèles ont été entraînés sur des visages recadrés (dataset UTKFace). En production, l'utilisateur prend une photo du corps entier ou dans un contexte réel.

MediaPipe détecte et isole le visage automatiquement avant de l'envoyer au modèle.

Comment ça marche

- ▶ Détection en 15-30ms
- ▶ Fonctionne même de loin
- ▶ Recadrage carré du visage
- ▶ Guide ovale en temps réel
- ▶ Rectangle vert quand un visage est détecté

Sans cette étape, le modèle analyserait les vêtements ou l'arrière-plan au lieu du visage.

Comment le modèle prédit-il ?

Le principe

Le modèle a appris par l'exemple à partir de 23 708 visages. Il détecte des patterns dans les pixels, comme un enfant qui apprend à reconnaître les visages.

Age

Rides, texture de peau,
cheveux gris, rondeur du
visage

Genre

Mâchoire, pilosité faciale,
structure osseuse

Ethnicité

Teint, forme des yeux et
du nez, proportions

Pas d'infrarouge ni de capteur spécial, uniquement les pixels

Ce que le modèle voit (Grad-CAM)

Cartes de chaleur : zones décisives pour chaque prédiction

Rouge = zone importante pour la décision, Bleu = zone ignorée



Le modèle se concentre sur le visage (pas les cheveux, vêtements ou arrière-plan). Cela confirme qu'il a appris des features

Le dataset UTKFace

23 708 images annotées

- ▶ Age : 0 a 116 ans
- ▶ Genre : Homme / Femme
- ▶ Ethnicite : 5 classes
- ▶ Split : 70% / 15% / 15%

Desequilibre

Blanc 45%, Noir 20%, Asiatique 15%, Indien 15%, Autre 5%
Compense par Focal Loss

Preprocessing

Resize 224x224 Augmentation (ip, crop, luminosite) Mixed precision oat16

Stratégie 1 : Trois modèles spécialisés

Principe

Un modèle dédié par tâche avec un backbone EfficientNetB0 pré-entraîné sur ImageNet.

Age

Sortie linéaire
Huber Loss
MAE ≈ 6.2
ans

Genre

Sortie sigmoid
Binary Cross-Entropy
Acc $\approx 90\%$

Ethnicite

Sortie softmax (5)
Focal Loss
Acc $\approx 70\%$

Entraînement : warmup (backbone gele) puis fine-tuning (15 couches)

Stratégie 2 : Modèle multi-tache

Principe

Un seul modèle Efficient NetB0 prédit les 3 tâches simultanément. Le backbone est partagé, seules les couches de sortie (Dense) sont spécifiques à chaque tâche.

Avantage

Un seul modèle, inférence plus rapide, le modèle apprend des features communes aux 3 tâches.

Inconvénient

Les tâches se partagent la capacité du modèle. Chaque tâche individuelle est légèrement moins bonne qu'un modèle spécialisé.

Mixture of Experts : Initiative personnelle

Pourquoi le MoE ?

Après nos recherches, nous avons voulu aller au-delà du sujet en testant une architecture Mixture of Experts pour améliorer le modèle multi-tache.

Comment ça marche

- ▶ 1 backbone EfficientNetB0 partagé
- ▶ 3 têtes avec 4 experts chacune
- ▶ 1 gating network par tâche
- ▶ Le gating choisit l'expert le plus adapté pour chaque visage

Résultat

- ▶ Genre : 90.7% accuracy
- ▶ Ethnicité : 70.8% accuracy
- ▶ Age : 6.36 ans MAE
- ▶ Meilleur que le multi-tache simple

Stratégie 3 : Comparaison des architectures

Architecture	Genre	Ethnicite	Age MAE	Taille	Score
E cientNetBo	90.1%	68.3%	6.19	5M	9.17
ResNet50	89.9%	66.9%	5.87	30M	9.15
MobileNetV3	88.5%	67.8%	7.11	4M	9.02
MobileNetV2	85.0%	55.7%	7.59	3M	8.37

Pourquoi E cientNetB0 ?

Meilleur compromis précision / taille. ResNet50 est quasi égal mais 6x plus gros et 2x plus lent.

Avantages et inconvénients de chaque mode

Mode	Avantages	Inconvénients
Hybride (défaut)	Meilleure précision grâce au TTA (ip + moyenne)	Charge 3 modèles en mémoire, plus lent
3 Spécialises	Chaque modèle optimise pour sa tâche	3 fichiers à charger, pas de partage de features
MoE	1 seul fichier, experts et spécialises par type de visage	Nécessite une librairie supplémentaire (select-tf-ops)

Le mode Hybride est recommandé : il combine les 3 modèles spécialisés avec du Test Time Augmentation pour des résultats plus stables.

L'application Android

Fonctionnalités

- ▶ Camera photo + temps réel
- ▶ Import depuis la galerie
- ▶ 3 modes de prédiction
- ▶ Historique avec filtres
- ▶ Mode sombre
- ▶ Tutoriel + gestion compte

Technologies

- ▶ Kotlin + Android SDK 34
- ▶ TensorFlow Lite (inférence)
- ▶ MediaPipe (détection visage)
- ▶ Firebase Auth + Firestore
- ▶ CameraX (temps réel)
- ▶ Material Design 3

Processus d'entraînement

Pipeline

1. Comparaison des backbone : On teste 4 architectures (MobileNetV2, EfficientNetB0, ResNet50, MobileNetV3) sur les 3 tâches. EfficientNetB0 gagne.
2. Entraînement multi-tâche MoE : On entraîne le modèle Mixture of Experts avec EfficientNetB0 en 3 phases (warmup, fine-tune partiel, fine-tune étendu).
3. Entraînement des 3 spécialises : Chaque modèle (age, genre, ethnicité) est entraîné séparément avec le même backbone.
4. Conversion TFLite : Les modèles Keras sont convertis en TensorFlow Lite (float16) pour le déploiement mobile.
5. Intégration Android : Les fichiers .tflite sont embarqués dans l'application.


Entraînement réalisé en local sur GPU NVIDIA RTX 4050 (6 Go VRAM) environ 3h

Prédictions visuelles

Exemples de prédictions sur le jeu de test

Vert = prédiction correcte (age ± 5 ans + genre + ethnicité)

Rouge = au moins une erreur



Mode Hybride teste sur 20 images : 95% genre, 90% ethnicité,
3.2 ans MAE

Résultats finaux

Tache	Metrique	Resultat	
Genre	Accuracy	90.7%	9 fois sur 10
	AUC	96.4%	
Ethnicite	Accuracy	70.8%	7 fois sur 10 (5 classes)
	AUC	90.6%	
Age	MAE	6.36 ans	erreur moyenne
	R ²	0.778	

Toutes les métriques du sujet : Accuracy, AUC, AP, MAE, MSE, R², ARI, NMI

Difficultés rencontrées

GPU limite (6 Go VRAM)

Crashes fréquents Batch réduit à 4, couches rebloques par paliers, nettoyage mémoire

Reproductibilité

Résultats variables. Seeds fixes pour numpy, tensorflow, random.

Dataset déséquilibre

Classe Autre = 5%. Focal Loss + poids de classe.

Confusion Asian / Indian

Traits proches. Limite du dataset, améliorable avec plus de données

Conclusion et perspectives

Bilan

- ▶ 3 stratégies implémentées + MoE en bonus
- ▶ Application Android fonctionnelle avec 3 modes
- ▶ 90.7% genre, 70.8% ethnicité, 6.36 ans MAE
- ▶ Temps réel, mode sombre, historique, export

Perspectives

- ▶ Dataset plus grand et équilibré
- ▶ Architectures récentes (Vision Transformers)
- ▶ Quantification int8 (APK plus légère)

Merci pour votre attention

Questions ?

Ako Christian Carld Similien Noe Cervera Dhanoush Kessavane

github.com/optmlako2004/face-analysis-deep-learning

IUT de Villetaneuse Université Sorbonne Paris Nord 2025-2026