

FacePredictor

Prediction d'âge, de genre et d'ethnecite
par Deep Learning

SAE BUT3 Informatique — 2025-2026

**Ako Christian — Calrd Similien — Noe Cervera — Dhanoush
Kessavane**

Encadrement : Bilal Faye

Sommaire

1. Demonstration de l'application
2. Comment ca marche ? (Detection de visage)
3. Les 3 strategies de modelisation
4. Mixture of Experts (initiative personnelle)
5. Comparaison des architectures
6. Avantages et inconvenients de chaque mode
7. Resultats
8. Difficultes et perspectives

Demonstration

Demo en direct de l'application

1. Photo

Prendre une photo
ou importer
depuis la galerie

2. Detection

MediaPipe detecte
et isole le visage
automatiquement

3. Resultat

Age, genre et
ethnicite predicts
avec confiance

Fonctionne aussi en temps reel via la camera

Detection de visage — MediaPipe

Pourquoi c'est necessaire ?

Nos modeles ont ete entraines sur des **visages recadres** (dataset UTKFace). En production, l'utilisateur prend une photo du **corps entier** ou dans un contexte reel.

MediaPipe **detecte et isole le visage** automatiquement avant de l'envoyer au modele.

Comment ca marche

- ▶ Detection en 15-30ms
- ▶ Fonctionne meme de loin
- ▶ Recadrage carre du visage
- ▶ Guide ovale en temps reel
- ▶ Rectangle vert quand un visage est detecte

Sans cette etape, le modele analyserait les vetements ou l'arriere-plan au lieu du visage

Comment le modele predit-il ?

Le principe

Le modele a **appris par l'exemple** a partir de 23 708 visages. Il detecte des **patterns** dans les pixels, comme un enfant qui apprend a reconnaitre les visages.

Age

Rides, texture de peau,
cheveux gris, rondeur du
visage

Genre

Machoire, pilosite faciale,
structure osseuse

Ethnicite

Teint, forme des yeux et
du nez, proportions

Pas d'infrarouge ni de capteur special — uniquement les pixels

Ce que le modele voit (Grad-CAM)

Cartes de chaleur : zones decisives pour chaque prediction

Rouge = zone importante pour la decision, Bleu = zone ignoree

[Insérer ici dans Canva :]

training/output_v2/gradcam_multitache.png

training/output_v2/gradcam_individuels.png

Le modele se concentre sur le **visage** (pas les cheveux, vetements ou arriere-plan).

Cela confirme qu'il a appris des features biologiquement coherentes.

Le dataset UTKFace

23 708 images annotées

- ▶ **Age** : 0 à 116 ans
- ▶ **Genre** : Homme / Femme
- ▶ **Ethnicité** : 5 classes
- ▶ **Split** : 70% / 15% / 15%

Desequilibre

Blanc 45%, Noir 20%, Asiatique 15%, Indien 15%, Autre 5%

Compense par **Focal Loss**

Preprocessing

Resize 224x224 — Augmentation (flip, crop, luminosité) — Mixed precision float16

Strategie 1 — Trois modeles specialises

Principe

Un modele dedie par tache avec un backbone **EfficientNetB0** pre-entraine sur ImageNet.

Age

Sortie lineaire
Huber Loss

MAE $\approx$ 6.2 ans

Genre

Sortie sigmoid
Binary Cross-Entropy

Acc $\approx$ 90%

Ethnicite

Sortie softmax (5)
Focal Loss

Acc $\approx$ 70%

Entrainement : warmup (backbone gele) puis fine-tuning (15 couches)

Strategie 2 — Modele multi-tache

Principe

Un seul modele EfficientNetB0 predit les 3 taches simultanement. Le backbone est partage, seules les couches de sortie (Dense) sont specifiques a chaque tache.

Avantage

Un seul fichier, inference plus rapide, le modele apprend des **features communes** aux 3 taches.

Inconvenient

Les taches se **partagent la capacite** du modele. Chaque tache individuelle est legerement moins bonne qu'un modele specialise.

Mixture of Experts — Initiative personnelle

Pourquoi le MoE ?

Après nos recherches, nous avons voulu aller **au-dela du sujet** en testant une architecture Mixture of Experts pour améliorer le modèle multi-tache.

Comment ça marche

- ▶ 1 backbone EfficientNetB0 partage
- ▶ 3 têtes avec **4 experts** chacune
- ▶ 1 **gating network** par tâche
- ▶ Le gating choisit l'expert le plus adapté pour chaque visage

Résultat

- ▶ Genre : **90.7%** accuracy
- ▶ Ethnicité : **70.8%** accuracy
- ▶ Age : **6.36 ans** MAE
- ▶ Meilleur que le multi-tâche simple

Strategie 3 — Comparaison des architectures

Architecture	Genre	Ethnicite	Age MAE	Taille	Score
EfficientNetB0	90.1%	68.3%	6.19	5M	9.17
ResNet50	89.9%	66.9%	5.87	30M	9.15
MobileNetV3	88.5%	67.8%	7.11	4M	9.02
MobileNetV2	85.0%	55.7%	7.59	3M	8.37

Pourquoi EfficientNetB0 ?

Meilleur compromis **precision** / **taille**. ResNet50 est quasi egal mais 6x plus gros et 2x plus lent.

Avantages et inconvénients de chaque mode

Mode	Avantages	Inconvénients
Hybride (default)	Meilleure précision grâce au TTA (flip + moyenne)	Charge 3 modèles en mémoire, plus lent
3 Spécialisés	Chaque modèle optimisé pour sa tâche	3 fichiers à charger, pas de partage de features
MoE	1 seul fichier, experts spécialisés par type de visage	Nécessite une librairie supplémentaire (select-tf-ops)

Le mode **Hybride** est recommandé : il combine les 3 modèles spécialisés avec du Test Time Augmentation pour des résultats plus stables.

L'application Android

Fonctionnalites

- ▶ Camera photo + **temps reel**
- ▶ Import depuis la galerie
- ▶ **3 modes** de prediction
- ▶ Historique avec filtres
- ▶ Mode sombre
- ▶ Tutoriel + gestion compte

Technologies

- ▶ **Kotlin** + Android SDK 34
- ▶ **TensorFlow Lite** (inference)
- ▶ **MediaPipe** (detection visage)
- ▶ **Firebase** Auth + Firestore
- ▶ **CameraX** (temps reel)
- ▶ Material Design 3

Processus d'entraînement

Pipeline

1. **Comparaison des backbones** — On teste 4 architectures (MobileNetV2, EfficientNetB0, ResNet50, MobileNetV3) sur les 3 tâches. EfficientNetB0 gagne.
2. **Entraînement multi-tâche MoE** — On entraîne le modèle Mixture of Experts avec EfficientNetB0 en 3 phases (warmup, fine-tune partiel, fine-tune étendu).
3. **Entraînement des 3 spécialisés** — Chaque modèle (âge, genre, ethnicité) est entraîné séparément avec le même backbone.
4. **Conversion TFLite** — Les modèles Keras sont convertis en TensorFlow Lite (float16) pour le déploiement mobile.
5. **Intégration Android** — Les fichiers .tflite sont embarqués dans l'application.

Predictions visuelles

Exemples de predictions sur le jeu de test

Vert = prediction correcte (age ± 5 ans + genre + ethnicite)

Rouge = au moins une erreur

*[Insérer ici : multitask_predictions_visuelles.png
et individuels_predictions_visuelles.png]*

Mode Hybride teste sur 20 images : **95%** genre, **90%** ethnicite, **3.2 ans** MAE

Resultats finaux

Tache	Metrique	Resultat
Genre	Accuracy	90.7% — 9 fois sur 10
	AUC	96.4%
Ethnicite	Accuracy	70.8% — 7 fois sur 10 (5 classes)
	AUC	90.6%
Age	MAE	6.36 ans — erreur moyenne
	R ²	0.778

Toutes les metriques du sujet : Accuracy, AUC, AP, MAE, MSE, R², ARI, NMI

Difficultes rencontrees

GPU limite (6 Go VRAM)

Crashes frequents. Batch reduit a 4, couches debloquees par paliers, nettoyage memoire.

Reproductibilite

Resultats variables. Seeds fixes pour numpy, tensorflow, random.

Dataset desequilibre

Classe "Autre" = 5%. Focal Loss + poids de classe.

Confusion Asian / Indian

Traits proches. Limite du dataset, ameliorable avec plus de donnees.

Conclusion et perspectives

Bilan

- ▶ 3 strategies implementees + MoE en bonus
- ▶ Application Android fonctionnelle avec 3 modes
- ▶ 90.7% genre, 70.8% ethnicite, 6.36 ans MAE
- ▶ Temps reel, mode sombre, historique, export

Perspectives

- ▶ Dataset plus grand et equilibre
- ▶ Architectures recentes (Vision Transformers)
- ▶ Quantification int8 (APK plus legere)

Merci pour votre attention

Questions ?

Ako Christian — Calrd Similien — Noe Cervera — Dhanoush Kessavane

github.com/optmlako2004/face-analysis-deep-learning

IUT de Villetaneuse — Université Sorbonne Paris Nord — 2025-2026